

SKRIPSI

**SEGMENTASI PELANGGAN MALL MENGGUNAKAN GAUSSIAN
MIXTURE MODEL (GMM) BERDASARKAN USIA, PENDAPATAN
TAHUNAN, DAN SKOR PENGELUARAN**



Oleh:

**Shela Rahma Fitri
24260012**

**PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS TEKNIK DAN ILMU KOMPUTER
UNIVERSITAS NAHDLATUL ULAMA INDONESIA
JAKARTA
2026**

**SEGMENTASI PELANGGAN MALL MENGGUNAKAN GAUSSIAN
MIXTURE MODEL (GMM) BERDASARKAN USIA, PENDAPATAN
TAHUNAN, DAN SKOR PENGELUARAN**

SKRIPSI

Diajukan sebagai salah satu syarat untuk memperoleh
Gelar Sarjana Komputer

Oleh:

**Shela Rahma Fitri
24260012**

**PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS TEKNIK DAN ILMU KOMPUTER
UNIVERSITAS NAHDLATUL ULAMA INDONESIA
JAKARTA
2026**

HALAMAN PERSETUJUAN

(Sebelum Sidang)

HALAMAN PENGESAHAN

(Setelah Sidang)

HALAMAN MOTTO

“Data yang baik akan berbicara dengan sendirinya jika diberi kesempatan untuk diolah dengan benar.”

HALAMAN PERSEMBAHAN

Skripsi ini penulis persembahkan kepada kedua orang tua, keluarga, dosen pembimbing, serta seluruh pihak yang telah memberikan dukungan, doa, dan semangat selama proses penyusunan skripsi ini.

PERNYATAAN KEASLIAN

Saya yang bertanda-tangan di bawah ini menyatakan bahwa skripsi ini merupakan karya saya sendiri (ASLI), dan isi dalam skripsi ini tidak terdapat karya yang pernah diajukan oleh orang lain untuk memperoleh gelar akademis di suatu Perguruan Tinggi, dan sepanjang pengetahuan saya juga tidak terdapat karya atau pendapat yang pernah ditulis dan/atau diterbitkan oleh orang lain, kecuali yang secara tertulis diacu dalam naskah ini dan disebutkan dalam daftar pustaka. Pernyataan ini saya buat dengan sesungguhnya, apabila di kemudian hari terdapat penyimpangan dan ketidakbenaran dalam pernyataan ini, maka saya bersedia menerima SANKSI AKADEMIK dengan pencabutan gelar yang sudah diperoleh, serta sanksi lainnya sesuai dengan norma yang berlaku di Perguruan Tinggi.

Dinyatakan di Jakarta
Tanggal

Materai 10rb
+ ttd

Shela Rahma Fitri
24260012

KATA PENGANTAR

Dengan mengucap puji dan syukur kehadiran Allah SWT, karena atas ridho dan hidayah-Nya, sehingga penulis dapat menyelesaikan Skripsi ini. Maksud dan tujuan dari penulisan Skripsi ini adalah untuk memenuhi persyaratan kelulusan Program Studi Strata I Teknik Informatika di Universitas Nahdlatul Ulama Indonesia.

Penulis merasa bahwa dalam menyusun laporan ini masih menemui beberapa kesulitan dan hambatan, disamping itu juga menyadari bahwa penulisan laporan ini masih jauh dari sempurna dan masih banyak kekurangan-kekurangan lainnya, maka dari itu penulis mengharapkan saran dan kritik yang membangun dari semua pihak.

Menyadari penyusunan laporan ini tidak lepas dari bantuan berbagai pihak, maka pada kesempatan ini penulis menyampaikan ucapan terima kasih yang setulus-tulusnya kepada: 1. 2. 3.

Akhir kata, semoga Allah SWT senantiasa melimpahkan karunia-Nya dan membalas segala amal budi serta kebaikan pihak-pihak yang telah membantu penulis dalam penyusunan laporan ini dan semoga tulisan ini dapat memberikan manfaat bagi pihak-pihak yang membutuhkan.

Jakarta, 1 April 2024

Penulis

DAFTAR ISI

DAFTAR TABEL

DAFTAR GAMBAR

DAFTAR RUMUS

ABSTRAK

Mall merupakan salah satu pusat perbelanjaan yang memiliki pelanggan dengan karakteristik beragam, sehingga strategi pemasaran yang seragam menjadi kurang efektif. Penelitian ini bertujuan untuk melakukan segmentasi pelanggan mall berdasarkan data usia, pendapatan tahunan, dan skor pengeluaran menggunakan metode Gaussian Mixture Model (GMM). Penelitian menggunakan dataset Mall Customers yang terdiri atas 200 data pelanggan. Tahapan penelitian meliputi pemuatan dataset, eksplorasi data (EDA), pemilihan fitur, standardisasi data menggunakan StandardScaler, penentuan jumlah cluster optimal berdasarkan nilai Bayesian Information Criterion (BIC) dan Akaike Information Criterion (AIC), pembentukan model GMM, pelabelan cluster, visualisasi hasil clustering, evaluasi model menggunakan Silhouette Score, serta analisis dan interpretasi karakteristik tiap cluster. Berdasarkan evaluasi nilai BIC pada rentang 1 hingga 10 cluster, diperoleh jumlah cluster optimal sebanyak 4 cluster dengan nilai BIC terendah sebesar 1596,999. Model GMM dengan 4 cluster menghasilkan nilai Silhouette Score sebesar 0,3734 yang menunjukkan struktur clustering berada pada kategori lemah hingga cukup (weak-to-moderate) menurut skala Kaufman dan Rousseeuw (1990), sehingga sebagian cluster masih menunjukkan tumpang tindih meskipun pola segmentasi secara umum tetap dapat diidentifikasi. Hasil segmentasi menunjukkan empat kelompok pelanggan dengan karakteristik berbeda, yaitu pelanggan berusia lebih tua dengan pengeluaran sedang, pelanggan berpendapatan dan pengeluaran tinggi, pelanggan muda dengan aktivitas belanja cukup tinggi, serta pelanggan berpendapatan tinggi namun pengeluaran rendah. Hasil penelitian ini dapat dimanfaatkan oleh pihak manajemen mall untuk menyusun strategi pemasaran yang lebih tepat sasaran bagi setiap segmen pelanggan.

Kata Kunci: segmentasi pelanggan, Gaussian Mixture Model, clustering, Silhouette Score, Mall Customers.

ABSTRACT

A mall is a shopping center whose customers exhibit diverse characteristics, making a uniform marketing strategy less effective. This study aims to perform customer segmentation in a mall based on age, annual income, and spending score data using the Gaussian Mixture Model (GMM) method. The study uses the Mall Customers dataset consisting of 200 customer records. The research stages include loading the dataset, exploratory data analysis (EDA), feature selection, data standardization using StandardScaler, determining the optimal number of clusters based on Bayesian Information Criterion (BIC) and Akaike Information Criterion (AIC) values, building the GMM model, assigning cluster labels, visualizing the clustering results, evaluating the model using the Silhouette Score, and analyzing and interpreting the characteristics of each cluster. Based on the BIC evaluation across 1 to 10 clusters, the optimal number of clusters was found to be 4, with the lowest BIC value of 1596.999. The GMM model with 4 clusters produced a Silhouette Score of 0.3734, indicating a fairly good clustering quality. The segmentation results reveal four customer groups with distinct characteristics: older customers with moderate spending, customers with high income and high spending, younger customers with fairly active spending, and customers with high income but low spending. These results can be used by mall management to design more targeted marketing strategies for each customer segment.

Keywords: customer segmentation, Gaussian Mixture Model, clustering, Silhouette Score, Mall Customers.

BAB 1

PENDAHULUAN

Bab ini akan menjelaskan tentang dasar dilakukannya penelitian dalam tugas akhir ini. Dasar penelitian tersebut terdiri dari latar belakang, rumusan masalah, batasan masalah, tujuan penelitian, target luaran, manfaat penelitian, metode, dan sistematika penulisan.

1.1. Latar Belakang

Industri ritel, termasuk pusat perbelanjaan (mall), menghadapi persaingan yang semakin ketat seiring dengan meningkatnya jumlah pelanggan dengan karakteristik perilaku belanja yang beragam. Setiap pelanggan memiliki usia, pendapatan, dan pola pengeluaran yang berbeda-beda, sehingga penerapan strategi pemasaran yang bersifat umum dan seragam menjadi kurang efektif dalam menjangkau kebutuhan masing-masing kelompok pelanggan (Kotler & Keller, 2016). Oleh karena itu, pemahaman terhadap karakteristik pelanggan menjadi salah satu kunci penting bagi perusahaan ritel untuk dapat menyusun strategi pemasaran yang lebih tepat sasaran.

Segmentasi pelanggan merupakan salah satu pendekatan yang dapat digunakan untuk mengelompokkan pelanggan ke dalam beberapa kelompok berdasarkan kesamaan karakteristik tertentu, sehingga setiap kelompok dapat diperlakukan dengan strategi pemasaran yang berbeda sesuai dengan kebutuhannya (Tsiptsis & Chorianopoulos, 2011). Pendekatan data mining, khususnya teknik clustering, banyak digunakan untuk melakukan segmentasi pelanggan secara otomatis berdasarkan data historis seperti usia, pendapatan tahunan, dan skor pengeluaran. Penggunaan teknik clustering memungkinkan perusahaan menemukan pola tersembunyi pada data pelanggan tanpa memerlukan label kelas yang telah ditentukan sebelumnya (Han, Kamber, & Pei, 2012).

Beberapa algoritma clustering telah banyak digunakan dalam penelitian segmentasi pelanggan, salah satunya adalah K-Means. Namun, K-Means memiliki keterbatasan karena mengasumsikan setiap cluster berbentuk bulat (spherical) dengan ukuran yang relatif sama, sehingga kurang fleksibel ketika distribusi data pelanggan tidak memenuhi asumsi tersebut (Reynolds, 2009). Gaussian Mixture Model (GMM) merupakan salah satu metode clustering berbasis probabilistik yang memodelkan data sebagai kombinasi dari beberapa distribusi Gaussian, sehingga mampu menangkap bentuk cluster yang lebih fleksibel serta memberikan probabilitas keanggotaan setiap data terhadap masing-masing cluster (Reynolds, 2009). Pemilihan jumlah cluster pada GMM dapat ditentukan secara objektif menggunakan kriteria statistik seperti Bayesian Information Criterion (BIC) dan Akaike Information Criterion (AIC),

sehingga proses penentuan jumlah cluster tidak hanya bergantung pada interpretasi visual semata (Bishop, 2006). Berdasarkan kelebihan tersebut, penelitian ini mengusulkan penggunaan metode GMM untuk melakukan segmentasi pelanggan pada dataset Mall Customers berdasarkan fitur usia, pendapatan tahunan, dan skor pengeluaran.

Berdasarkan uraian tersebut, penelitian ini dilakukan dengan judul "Segmentasi Pelanggan Mall Menggunakan Gaussian Mixture Model (GMM) Berdasarkan Usia, Pendapatan Tahunan, dan Skor Pengeluaran". Hasil segmentasi yang diperoleh diharapkan dapat memberikan gambaran karakteristik masing-masing kelompok pelanggan, sehingga dapat dimanfaatkan oleh pihak manajemen mall sebagai dasar dalam menyusun strategi pemasaran yang lebih tepat sasaran bagi setiap segmen pelanggan.

1.2. Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah dalam penelitian ini adalah sebagai berikut:

- 1) Berapa jumlah cluster optimal untuk segmentasi pelanggan mall berdasarkan fitur usia, pendapatan tahunan, dan skor pengeluaran menggunakan metode Gaussian Mixture Model (GMM)?
- 2) Bagaimana karakteristik masing-masing cluster pelanggan yang dihasilkan oleh model Gaussian Mixture Model (GMM)?
- 3) Bagaimana kualitas hasil clustering yang dihasilkan oleh model Gaussian Mixture Model (GMM) yang diukur menggunakan Silhouette Score?

1.3. Batasan Masalah

Agar penelitian ini lebih terarah dan tidak meluas, maka diperlukan batasan masalah sebagai berikut:

Jumlah atau sumber data Penelitian ini menggunakan dataset Mall Customers yang terdiri atas 200 data pelanggan yang diperoleh dari platform Kaggle.

Fitur yang digunakan dalam proses clustering hanya terbatas pada usia (Age), pendapatan tahunan (Annual Income), dan skor pengeluaran (Spending Score), sedangkan fitur CustomerID dan Gender tidak digunakan dalam proses pemodelan.

Penelitian ini menggunakan bahasa pemrograman Python dengan library Pandas, NumPy, Matplotlib, Seaborn, dan Scikit-learn, dijalankan pada lingkungan Jupyter Notebook.

Metode clustering yang digunakan dalam penelitian ini hanya Gaussian Mixture Model (GMM), tanpa membandingkan dengan metode clustering lain.

1.4. Tujuan Penelitian

Berdasarkan rumusan masalah yang telah dipaparkan, tujuan penelitian ini adalah sebagai berikut: (1) menentukan jumlah cluster optimal untuk segmentasi pelanggan mall berdasarkan fitur usia, pendapatan tahunan, dan skor pengeluaran menggunakan metode Gaussian Mixture Model (GMM) dengan bantuan nilai BIC dan AIC; (2) menganalisis karakteristik masing-masing cluster pelanggan yang dihasilkan oleh model GMM; dan (3) mengevaluasi kualitas hasil clustering yang dihasilkan oleh model GMM menggunakan Silhouette Score.

1.5. Manfaat Penelitian

Hasil penelitian ini diharapkan dapat memberikan manfaat bagi beberapa pihak, antara lain:

- 1) Pihak manajemen mall: hasil segmentasi pelanggan dapat digunakan sebagai dasar dalam menyusun strategi pemasaran yang lebih tepat sasaran bagi setiap kelompok pelanggan.
- 2) Pihak akademisi: penelitian ini dapat menjadi referensi tambahan mengenai penerapan metode Gaussian Mixture Model (GMM) dalam permasalahan segmentasi pelanggan.
- 3) Bagi penulis: penelitian ini menjadi sarana untuk menerapkan dan memperdalam pemahaman mengenai teknik clustering berbasis probabilitas, khususnya Gaussian Mixture Model (GMM), pada permasalahan nyata di bidang data mining.

1.6. Metode Penelitian

Penelitian ini dilakukan melalui beberapa tahapan. Adapun metode yang digunakan dalam tiap-tiap tahapan antara lain:

1) Metode Pengumpulan Data

Pengumpulan data dilakukan melalui studi pustaka dan penelusuran dataset sekunder yang tersedia secara publik. Dataset yang digunakan adalah Mall Customers Dataset dalam format csv yang diperoleh dari platform Kaggle, terdiri atas 200 data pelanggan dengan atribut CustomerID, Gender, Age, Annual Income (k\$), dan Spending Score (1-100).

2) Metode Analisis Data

Dataset (csv) dikelola menggunakan bahasa pemrograman Python dengan bantuan library Pandas dan NumPy untuk pengolahan data, Matplotlib dan Seaborn untuk visualisasi data eksploratif (EDA), serta Scikit-learn untuk proses standardisasi data, pembentukan model Gaussian Mixture Model (GMM), dan evaluasi model.

3) Metode Pemodelan dan Validasi Data

a. Membangun skenario model

Skenario penelitian dirancang dengan menentukan fitur yang digunakan (usia, pendapatan tahunan, dan skor pengeluaran), melakukan standardisasi data menggunakan StandardScaler, kemudian menentukan jumlah cluster optimal melalui evaluasi nilai BIC dan AIC pada rentang 1 hingga 10 cluster.

b. Membangun model

Model dibangun menggunakan algoritma Gaussian Mixture Model (GMM) dari library Scikit-learn dengan jumlah cluster optimal hasil evaluasi BIC, kemudian model digunakan untuk memprediksi label cluster pada setiap data pelanggan.

c. Mengevaluasi model

Evaluasi model dilakukan dengan menghitung nilai Silhouette Score untuk mengukur kualitas hasil clustering, serta menganalisis karakteristik rata-rata usia, pendapatan tahunan, dan skor pengeluaran pada setiap cluster yang terbentuk.

1.7. Sistematika Penulisan

Sistem penulisan dalam tugas akhir ini disusun dalam bentuk karya ilmiah dengan struktur penulisan sebagai berikut:

BAB 1 PENDAHULUAN

Bab ini berisi uraian tentang latar belakang masalah yang mendasari pentingnya diadakan penelitian, identifikasi, pembatasan dan perumusan masalah penelitian, maksud dan tujuan penelitian, kegunaan penelitian yang diharapkan, dan sistematika penulisan.

BAB 2 LANDASAN TEORI

Bab ini berisi tinjauan pustaka mengenai penelitian terdahulu serta landasan teori terkait segmentasi pelanggan, data mining, clustering, dan metode Gaussian Mixture Model (GMM) yang digunakan dalam penelitian ini.

BAB 3 ANALISIS DAN PERANCANGAN SISTEM

Bab ini berisi metodologi penelitian yang meliputi kerangka berpikir, proses pengumpulan dan pengolahan data, serta perancangan model Gaussian Mixture Model (GMM) dan teknik evaluasi yang digunakan untuk menilai hasil clustering.

BAB 4 TESTING DAN IMPLEMENTASI

Bab ini berisi penjelasan implementasi dan eksperimen model Gaussian Mixture Model (GMM), mulai dari persiapan data, pembentukan model, hingga hasil dan analisis clustering yang diperoleh.

BAB 5 PENUTUP

Bab ini berisi pokok-pokok kesimpulan dan saran-saran yang perlu disampaikan kepada pihak-pihak yang berkepentingan dengan hasil penelitian.

DAFTAR PUSTAKA

Daftar pustaka berisi daftar referensi yang digunakan dalam penelitian.

BAB 2 TINJAUAN PUSTAKA

Bab ini memaparkan tentang penelitian-penelitian terdahulu yang berhubungan dengan topik skripsi. Bab 2 ini juga menjelaskan teori-teori yang digunakan oleh penulis dalam pembuatan tugas akhir/skripsi.

2.1. Penelitian Terdahulu

Penelitian terdahulu digunakan sebagai acuan dan pembanding untuk menunjukkan posisi serta keaslian penelitian ini. Beberapa penelitian terdahulu yang relevan dengan topik segmentasi pelanggan menggunakan metode clustering, khususnya Gaussian Mixture Model (GMM), disajikan pada tabel berikut.

Berdasarkan uraian penelitian terdahulu pada tabel di atas, penelitian ini memiliki posisi yang berbeda karena secara khusus menerapkan metode Gaussian Mixture Model (GMM) pada dataset Mall Customers dengan tiga fitur yaitu usia, pendapatan tahunan, dan skor pengeluaran, disertai penentuan jumlah cluster optimal berdasarkan nilai BIC dan AIC, evaluasi kualitas clustering menggunakan Silhouette Score, serta analisis karakteristik tiap cluster secara mendalam.

No	Penelitian Terdahulu	Kekurangan	Usulan
1	Perdana, Florentin, & Santoso (2022) melakukan segmentasi pelanggan aplikasi Alfagift menggunakan algoritma K-Means berdasarkan data transaksi pelanggan.	K-Means mengasumsikan cluster berbentuk bulat (spherical) dengan ukuran seragam, sehingga kurang optimal pada data dengan distribusi yang tidak simetris.	Penelitian ini mengusulkan penggunaan Gaussian Mixture Model (GMM) yang lebih fleksibel dalam memodelkan bentuk cluster.
2	John, Shobayo, & Ogunleye (2023) membandingkan K-Means, GMM, DBSCAN, Agglomerative, dan BIRCH untuk segmentasi pelanggan ritel menggunakan model RFM, dengan GMM menghasilkan Silhouette Score tertinggi sebesar 0,80.	Penelitian tersebut menggunakan dataset transaksi online skala besar dengan pendekatan RFM dan PCA yang berbeda konteks dengan data demografis pelanggan mall, serta belum menyertakan penentuan jumlah cluster berbasis BIC/AIC untuk GMM.	Penelitian ini menggunakan GMM dengan penentuan jumlah cluster secara objektif berdasarkan nilai BIC dan AIC.
3	Laksana & Fahrezi (2024) menerapkan Gaussian Mixture Model (GMM) untuk segmentasi pelanggan berdasarkan data perilaku konsumen digital dan	Penelitian tersebut berfokus pada data perilaku konsumen digital dalam konteks pemasaran digital secara umum, tanpa menampilkan rincian	Penelitian ini melengkapi pendekatan GMM dengan evaluasi kuantitatif menggunakan BIC, AIC, dan Silhouette Score secara eksplisit, serta

	memperoleh 4 cluster optimal sebagai dasar strategi pemasaran.	evaluasi model menggunakan BIC/AIC maupun Silhouette Score secara eksplisit.	analisis karakteristik cluster berdasarkan data demografis dan perilaku belanja pelanggan mall.
--	--	--	---

Selain itu, bagian ini berisi justifikasi atau kritik pada kelemahan atau kekurangan yang mungkin ada pada penelitian terdahulu sehingga dapat dijadikan argumen bahwa penelitian yang akan dilakukan bersifat penyempurnaan atau pengembangan penelitian terdahulu. Sumber pustaka yang dirujuk pada bagian ini harus dicantumkan dalam kalimat atau pernyataan yang diacu dan dicantumkan dalam daftar pustaka.

2.2. Landasan Teori

Bagian ini memuat teori-teori yang mendukung penelitian, meliputi konsep data mining, clustering, Gaussian Mixture Model (GMM), kriteria pemilihan jumlah cluster menggunakan Bayesian Information Criterion (BIC) dan Akaike Information Criterion (AIC), serta Silhouette Score sebagai metode evaluasi hasil clustering.

2.2.1. Data Mining dan Clustering

Data mining merupakan proses penggalian pola, hubungan, atau informasi penting yang tersembunyi dari sekumpulan data berukuran besar dengan menggunakan pendekatan statistik, matematika, dan kecerdasan buatan (Han, Kamber, & Pei, 2012). Salah satu teknik data mining yang bersifat unsupervised learning adalah clustering, yaitu proses pengelompokan data ke dalam beberapa kelompok (cluster) berdasarkan tingkat kemiripan karakteristik antar data, di mana data pada satu cluster memiliki kemiripan yang tinggi, sedangkan data pada cluster yang berbeda memiliki tingkat kemiripan yang rendah (Tan, Steinbach, & Kumar, 2019). Clustering banyak diterapkan pada permasalahan segmentasi pelanggan karena mampu mengelompokkan pelanggan tanpa memerlukan label kelas yang telah ditentukan sebelumnya.

2.2.2. Gaussian Mixture Model (GMM)

Gaussian Mixture Model (GMM) adalah metode clustering berbasis probabilistik yang mengasumsikan bahwa data terbentuk dari kombinasi beberapa distribusi Gaussian (normal), di mana setiap distribusi Gaussian merepresentasikan satu cluster dengan parameter rata-rata (mean), matriks kovarians, dan bobot campuran (mixture weight) tersendiri (Reynolds, 2009). Berbeda dengan K-Means yang melakukan pengelompokan secara hard clustering (satu data hanya menjadi anggota satu cluster), GMM melakukan soft clustering dengan memberikan nilai probabilitas keanggotaan setiap data terhadap masing-masing cluster (Bishop, 2006). Estimasi parameter pada GMM umumnya dilakukan menggunakan algoritma Expectation-Maximization (EM), yang secara iteratif memperbarui probabilitas keanggotaan data (langkah E) dan memperbarui parameter distribusi Gaussian (langkah M) hingga konvergen (Bishop, 2006). Karakteristik inilah yang membuat GMM lebih fleksibel dalam memodelkan cluster dengan bentuk dan ukuran yang bervariasi dibandingkan metode clustering berbasis jarak seperti K-Means.

2.2.3. Bayesian Information Criterion (BIC) dan Akaike Information Criterion (AIC)

Salah satu tantangan dalam penerapan GMM adalah menentukan jumlah cluster (komponen Gaussian) yang optimal. Bayesian Information Criterion (BIC) dan Akaike

Information Criterion (AIC) merupakan kriteria statistik yang digunakan untuk memilih jumlah cluster terbaik dengan mempertimbangkan kesesuaian model terhadap data (likelihood) serta kompleksitas model (jumlah parameter) (Bishop, 2006). Semakin rendah nilai BIC atau AIC yang dihasilkan oleh suatu model, maka model tersebut dianggap semakin baik dalam merepresentasikan data tanpa mengalami overfitting. BIC memberikan penalti terhadap kompleksitas model yang lebih besar dibandingkan AIC, sehingga BIC cenderung menghasilkan jumlah cluster yang lebih sederhana (parsimonious) dan umum digunakan sebagai acuan utama dalam pemilihan jumlah cluster pada GMM.

2.2.4. Silhouette Score

Silhouette Score merupakan salah satu metrik evaluasi internal yang digunakan untuk mengukur kualitas hasil clustering tanpa memerlukan label kelas sebenarnya. Nilai Silhouette Score dihitung berdasarkan perbandingan antara jarak rata-rata suatu data terhadap data lain dalam cluster yang sama (kohesi) dengan jarak rata-rata terhadap data pada cluster terdekat lainnya (separasi) (Rousseeuw, 1987). Nilai Silhouette Score berkisar antara -1 hingga 1, di mana nilai yang mendekati 1 menunjukkan bahwa data telah dikelompokkan dengan tepat dan memiliki pemisahan antar cluster yang baik, nilai mendekati 0 menunjukkan tumpang tindih antar cluster, sedangkan nilai negatif menunjukkan kemungkinan data berada pada cluster yang salah. Sebagai acuan interpretasi kuantitatif, Kaufman dan Rousseeuw (1990) mengusulkan skala berikut: nilai di atas 0,70 menunjukkan struktur cluster yang kuat, 0,50 hingga 0,70 menunjukkan struktur yang cukup masuk akal, 0,25 hingga 0,50 menunjukkan struktur yang lemah dan berpotensi bersifat artifisial, sedangkan nilai di bawah 0,25 menunjukkan tidak ditemukannya struktur cluster yang substansial.


BAB 3

METODOLOGI PENELITIAN

Bab ini berisi metodologi penelitian yang digunakan, mulai dari kerangka berpikir, pengumpulan dan pengolahan data, hingga perancangan dan evaluasi model Gaussian Mixture Model (GMM) yang diusulkan. Bab ini terdiri dari beberapa sub-bab yang dijelaskan secara rinci sesuai dengan tahapan yang diterapkan pada program.

3.1. Kerangka Berpikir

Kerangka berpikir dalam penelitian ini menggambarkan alur tahapan yang dilakukan mulai dari data mentah hingga diperoleh hasil segmentasi pelanggan. Tahapan tersebut meliputi: (1) memuat dataset Mall Customers; (2) melakukan eksplorasi data (EDA) untuk memahami karakteristik data; (3) memilih fitur yang relevan, yaitu Age, Annual Income (k\$), dan Spending Score (1-100); (4) melakukan standardisasi data menggunakan StandardScaler agar seluruh fitur memiliki skala yang setara; (5) menentukan jumlah cluster optimal berdasarkan nilai BIC dan AIC pada rentang 1 hingga 10 cluster; (6) membangun model Gaussian Mixture Model (GMM) dengan jumlah cluster terbaik; (7) menambahkan label cluster hasil prediksi pada dataset; (8) memvisualisasikan hasil clustering; (9) mengevaluasi model menggunakan Silhouette Score; serta (10) menganalisis dan menginterpretasikan karakteristik masing-masing cluster yang terbentuk. Alur tahapan tersebut disajikan pada gambar kerangka berpikir berikut.



Gambar 3.1 Kerangka Berpikir Penelitian

3.2. Pengumpulan dan Pengolahan Data

Proses pengumpulan dan pengolahan data pada penelitian ini mengikuti tahapan yang diterapkan pada program, dimulai dari pemuatan dataset hingga data siap digunakan untuk pemodelan Gaussian Mixture Model (GMM). Penjelasan masing-masing tahapan dijabarkan pada sub-bab berikut.

3.2.1. Pengumpulan Data

Data yang digunakan dalam penelitian ini adalah dataset Mall Customers dalam format csv yang diperoleh dari platform Kaggle. Dataset dimuat ke dalam program menggunakan library Pandas melalui fungsi `pd.read_csv()`, kemudian dilakukan pemahaman awal terhadap struktur data menggunakan fungsi `head()`, `info()`, `describe()`, dan pengecekan nilai kosong (missing value) menggunakan `isnull().sum()`. Hasil pemeriksaan menunjukkan bahwa dataset terdiri atas 200 baris data dengan lima kolom, yaitu CustomerID, Gender, Age, Annual Income (k\$), dan Spending Score (1-100), tanpa ditemukan nilai kosong pada seluruh kolom.

3.2.2. Pengolahan Data

Setelah tahap pemahaman data, dilakukan eksplorasi data (Exploratory Data Analysis/EDA) untuk melihat sebaran nilai pada fitur Age, Annual Income (k\$), dan Spending Score (1-100) melalui visualisasi histogram menggunakan library Matplotlib dan Seaborn. Selanjutnya dilakukan pemilihan fitur (feature selection), yaitu memilih tiga fitur numerik yang relevan untuk proses clustering, meliputi Age, Annual Income (k\$), dan Spending Score (1-100), sedangkan fitur CustomerID dan Gender tidak diikutsertakan. Ketiga fitur terpilih kemudian distandardisasi menggunakan StandardScaler dari library Scikit-learn agar seluruh fitur memiliki skala rata-rata nol dan standar deviasi satu, sehingga tidak ada fitur yang mendominasi proses perhitungan jarak akibat perbedaan satuan dan rentang nilai.

3.3. Perancangan Teknik/Model (*Gaussian Mixture Model*)

Perancangan model pada penelitian ini menggunakan algoritma Gaussian Mixture Model (GMM) yang tersedia pada library Scikit-learn melalui kelas GaussianMixture. Tahap awal perancangan adalah menentukan jumlah cluster optimal, dilakukan dengan melatih model GMM untuk setiap kemungkinan jumlah cluster dari 1 sampai 10, kemudian dihitung nilai Bayesian Information Criterion (BIC) dan Akaike Information Criterion (AIC) untuk masing-masing jumlah cluster. Jumlah cluster dengan nilai BIC terendah dipilih sebagai jumlah cluster

optimal. Berdasarkan hasil evaluasi, diperoleh nilai BIC terendah pada 4 cluster sebesar 1596,999, sehingga model akhir dibangun dengan parameter `n_components=4` dan `random_state=42`. Model kemudian dilatih (fit) menggunakan data yang telah distandardisasi, dan digunakan untuk memprediksi label cluster pada setiap data pelanggan melalui fungsi `predict()`, yang selanjutnya ditambahkan sebagai kolom baru bernama Cluster pada dataset.

3.4. Evaluasi Teknik/Model (*Silhouette Score*)

Evaluasi kualitas hasil clustering pada penelitian ini menggunakan Silhouette Score, yang dihitung menggunakan fungsi `silhouette_score()` dari library Scikit-learn dengan masukan berupa data yang telah distandardisasi beserta label cluster hasil prediksi model GMM. Selain evaluasi kuantitatif menggunakan Silhouette Score, dilakukan pula evaluasi kualitatif melalui visualisasi hasil clustering menggunakan scatter plot antara fitur Annual Income dan Spending Score, serta analisis rata-rata nilai Age, Annual Income, dan Spending Score pada masing-masing cluster untuk menginterpretasikan karakteristik setiap segmen pelanggan yang terbentuk.

BAB 4

IMPLEMENTASI DAN EKSPERIMEN

Pada bab ini akan dijelaskan hasil-hasil dari implementasi dan eksperimen model Gaussian Mixture Model (GMM) yang dilakukan pada dataset Mall Customers, mulai dari persiapan data, pembentukan model, hasil clustering, hingga evaluasi dan analisis karakteristik masing-masing cluster yang terbentuk.

4.1. Persiapan Data

Bagian ini menjelaskan tahap persiapan data yang dilakukan sebelum data digunakan dalam pembentukan model Gaussian Mixture Model (GMM). Persiapan data meliputi pengumpulan dataset dan pengolahan data melalui eksplorasi, pemilihan fitur, serta standarisasi data.


4.1.1. Pengumpulan Data

Dataset yang digunakan dalam implementasi ini adalah Mall_Customers.csv yang dimuat menggunakan fungsi `pd.read_csv()` pada library Pandas. Dataset terdiri atas 200 baris data pelanggan dengan lima kolom, yaitu CustomerID, Gender, Age, Annual Income (k\$), dan Spending Score (1-100). Pemeriksaan awal menggunakan fungsi `head()` menunjukkan struktur data yang konsisten, sedangkan fungsi `info()` dan `describe()` digunakan untuk melihat tipe data dan statistik deskriptif tiap kolom. Hasil pengecekan menggunakan `isnull().sum()` menunjukkan tidak terdapat nilai kosong (missing value) pada seluruh kolom, sehingga dataset dapat langsung digunakan pada tahap selanjutnya tanpa memerlukan proses imputasi data.

4.1.2. Pengolahan Data

Tahap pengolahan data diawali dengan eksplorasi data (Exploratory Data Analysis/EDA) untuk memahami sebaran nilai pada fitur Age, Annual Income (k\$), dan Spending Score (1-100) menggunakan visualisasi histogram. Hasil visualisasi menunjukkan bahwa usia pelanggan tersebar pada rentang sekitar 18 hingga 70 tahun, pendapatan tahunan tersebar pada rentang sekitar 15 hingga 137 ribu dolar, dan skor pengeluaran tersebar pada rentang 1 hingga 99. Selanjutnya dilakukan pemilihan fitur (feature selection) dengan memilih tiga fitur numerik, yaitu Age, Annual Income (k\$), dan Spending Score (1-100), sebagai variabel yang digunakan dalam proses clustering. Ketiga fitur tersebut kemudian distandarisasi menggunakan StandardScaler dari library Scikit-learn sehingga menghasilkan data dengan rata-rata mendekati 0 dan standar deviasi mendekati 1 pada setiap fitur, guna

menyamakan skala antar fitur sebelum digunakan dalam pembentukan model Gaussian Mixture Model (GMM).




Gambar 4.1 Visualisasi Eksplorasi Data (EDA) Fitur Age, Annual Income, dan Spending Score

4.2. Implementasi Teknik/Model

Bagian ini menjelaskan implementasi model Gaussian Mixture Model (GMM) yang diusulkan dalam penelitian, mulai dari penentuan jumlah cluster optimal hingga pembentukan model akhir.

4.2.1. Penentuan Jumlah Cluster Optimal (BIC dan AIC)

Penentuan jumlah cluster optimal dilakukan dengan melatih model Gaussian Mixture Model (GMM) untuk setiap jumlah cluster dari 1 hingga 10 menggunakan data yang telah distandardisasi. Untuk setiap jumlah cluster, dihitung nilai Bayesian Information Criterion (BIC) dan Akaike Information Criterion (AIC) menggunakan fungsi `bic()` dan `aic()` dari objek `GaussianMixture`. Hasil perhitungan menunjukkan nilai BIC terendah sebesar 1596,999 diperoleh pada jumlah 4 cluster, sedangkan nilai AIC terendah sebesar 1399,992 diperoleh pada jumlah 9 cluster. Pada penelitian ini, jumlah cluster dipilih berdasarkan nilai BIC karena memberikan keseimbangan antara Tingkat kecocokan model dan kompleksitas model. Berdasarkan hasil perhitungan, nilai BIC terendah diperoleh pada empat cluster sehingga digunakan sebagai model akhir penelitian.



Gambar 4.2 Grafik Nilai BIC dan AIC untuk Penentuan Jumlah Cluster

4.2.2. Pembangunan Model dan Pelabelan Cluster

Model akhir dibangun menggunakan kelas GaussianMixture dari library Scikit-learn dengan parameter `n_components=4` dan `random_state=42`. Model dilatih (fit) menggunakan data hasil standarisasi dari fitur Age, Annual Income (k\$), dan Spending Score (1-100). Setelah proses pelatihan selesai, model digunakan untuk memprediksi label cluster pada setiap data pelanggan melalui fungsi `predict()`, dan hasil prediksi tersebut ditambahkan sebagai kolom baru bernama Cluster pada dataset.


4.3. Hasil dan Analisis

Bagian ini menjelaskan hasil dari implementasi model Gaussian Mixture Model (GMM) yang dilakukan. Analisis hasil meliputi visualisasi clustering, evaluasi menggunakan Silhouette Score, serta interpretasi karakteristik masing-masing cluster yang terbentuk.

4.3.1. Visualisasi Hasil Clustering

Hasil clustering divisualisasikan menggunakan scatter plot antara fitur Annual Income (k\$) pada sumbu x dan Spending Score (1-100) pada sumbu y, dengan warna titik merepresentasikan label cluster hasil prediksi model GMM. Visualisasi hasil clustering menunjukkan adanya kecenderungan pemisahan antarcluster berdasarkan kombinasi Annual Income dan Spending Score. Namun demikian, masih terdapat beberapa area yang saling tumpang tindih sehingga hasil visualisasi ini sejalan dengan nilai silhouette score sebesar 0,3734 yang menunjukkan kualitas clustering berada pada kategori lemah hingga cukup.

Berdasarkan hasil pelabelan, diperoleh jumlah anggota masing-masing cluster sebagai berikut: Cluster 0 sebanyak 76 pelanggan, Cluster 1 sebanyak 39 pelanggan, Cluster 2 sebanyak 51 pelanggan, dan Cluster 3 sebanyak 34 pelanggan.



Gambar 4.3 Visualisasi Hasil Clustering Pelanggan Menggunakan GMM


4.3.2. Evaluasi Model Menggunakan Silhouette Score

Evaluasi kualitas hasil clustering dilakukan menggunakan Silhouette Score yang dihitung dengan fungsi `silhouette_score()` dari library Scikit-learn. Hasil perhitungan menunjukkan nilai Silhouette Score sebesar 0,3734 untuk model GMM dengan 4 cluster. Berdasarkan skala interpretasi Kaufman dan Rousseeuw (1990), nilai pada rentang 0,25 hingga 0,50 tergolong struktur clustering yang lemah (weak structure) dan berpotensi menunjukkan tumpang tindih antar cluster, sehingga hasil ini mengindikasikan bahwa meskipun keempat cluster dapat dibedakan, terdapat tumpang tindih (overlap) yang cukup terlihat pada sebagian data antar cluster, khususnya pada cluster dengan nilai pendapatan dan skor pengeluaran menengah. Hasil ini menunjukkan bahwa model GMM dengan 4 cluster mampu mengelompokkan pelanggan menjadi beberapa segmen yang dapat dibedakan, namun dengan tingkat pemisahan yang belum sepenuhnya tegas antar sebagian cluster.

4.3.3. Pembahasan Temuan

Analisis karakteristik dilakukan dengan menghitung rata-rata nilai Age, Annual Income (k\$), dan Spending Score (1-100) pada masing-masing cluster menggunakan fungsi `groupby()`. Berdasarkan hasil analisis, diperoleh karakteristik tiap cluster sebagai berikut. Cluster 0 (76 pelanggan) memiliki rata-rata usia 50,18 tahun, pendapatan tahunan 45,84 ribu dolar, dan skor

pengeluaran 40,70, yang mengindikasikan kelompok pelanggan berusia lebih tua dengan pendapatan dan pengeluaran pada tingkat menengah. Cluster 1 (39 pelanggan) memiliki rata-rata usia 32,69 tahun, pendapatan tahunan 86,54 ribu dolar, dan skor pengeluaran 82,13, yang menunjukkan kelompok pelanggan dengan pendapatan tinggi sekaligus pengeluaran yang tinggi, karakteristik tersebut menunjukkan bahwa pelanggan pada cluster 1 berpotensi menjadi target utama strategi pemasaran premium maupun program loyalitas karena memiliki Tingkat pendapatan dan pengeluaran yang tinggi dibandingkan cluster lain. Cluster 2 (51 pelanggan) memiliki rata-rata usia 24,33 tahun, pendapatan tahunan 43,90 ribu dolar, dan skor pengeluaran 61,75, yang mengindikasikan kelompok pelanggan berusia muda dengan pendapatan menengah namun memiliki aktivitas belanja yang cukup tinggi, kelompok pelanggan ini menunjukkan potensi sebagai target promosi produk yang mengikuti tren karena didominasi pelanggan berusia muda dengan kecenderungan aktivitas belanja yang relative tinggi. Cluster 3 (34 pelanggan) memiliki rata-rata usia 42,35 tahun, pendapatan tahunan 88,65 ribu dolar, dan skor pengeluaran 17,50, yang menunjukkan kelompok pelanggan dengan pendapatan tinggi namun cenderung berhemat atau memiliki pengeluaran yang rendah, meskipun memiliki Tingkat pendapatan yang tinggi, pelanggan pada cluster 3 menunjukkan kecenderungan pengeluaran yang rendah. Kondisi ini dapat mengindikasikan bahwa pelanggan bersifat lebih selektif dalam berbelanja sehingga strategi promosi yang lebih personal dapat di pertimbangkan. Hasil segmentasi menunjukkan bahwa kombinasi fitur usia, pendapatan tahunan, dan skor pengeluaran mampu membentuk karakteristik pelanggan yang berbeda pada setiap cluster. Informasi tersebut dapat dimanfaatkan sebagai dasar penyusunan strategi pemasaran yang lebih tepat sasaran sesuai karakteristik masing-masing kelompok pelanggan, misalnya program loyalitas untuk Cluster 1, promosi hemat untuk Cluster 3, serta penawaran produk sesuai tren bagi Cluster 2 yang didominasi pelanggan muda.



Gambar 4.4 Grafik Rata-rata Karakteristik Tiap Cluster

4.3.4. Hasil

Berdasarkan seluruh tahapan implementasi dan eksperimen yang telah dilakukan, penelitian ini berhasil melakukan segmentasi pelanggan mall ke dalam 4 cluster menggunakan metode Gaussian Mixture Model (GMM), dengan jumlah cluster optimal ditentukan berdasarkan nilai BIC terendah sebesar 1596,999. Model GMM yang dibangun menghasilkan nilai Silhouette Score sebesar 0,3734, yang menurut skala Kaufman dan Rousseeuw (1990) menunjukkan struktur clustering berada pada kategori lemah hingga cukup, mengindikasikan bahwa keempat cluster dapat dibedakan meskipun sebagian data menunjukkan tumpang tindih antar cluster. Hasil segmentasi menunjukkan empat kelompok pelanggan dengan karakteristik yang berbeda, yaitu pelanggan berusia lebih tua dengan pengeluaran sedang (Cluster 0), pelanggan berpendapatan dan pengeluaran tinggi (Cluster 1), pelanggan muda dengan aktivitas belanja cukup tinggi (Cluster 2), serta pelanggan berpendapatan tinggi namun pengeluaran rendah (Cluster 3). Berdasarkan hasil implementasi dan evaluasi model, seluruh tujuan penelitian berhasil dicapai sesuai dengan rumusan masalah yang telah ditetapkan pada BAB I.

BAB 5

PENUTUP

Bab ini berisi pokok-pokok kesimpulan dan saran-saran yang perlu disampaikan kepada pihak-pihak yang berkepentingan dengan hasil penelitian.

5.1. Kesimpulan

Berdasarkan hasil penelitian dan pembahasan yang telah diuraikan pada bab sebelumnya, dapat ditarik kesimpulan sebagai berikut. Pertama, jumlah cluster optimal untuk segmentasi pelanggan mall berdasarkan fitur usia, pendapatan tahunan, dan skor pengeluaran menggunakan Gaussian Mixture Model (GMM) adalah 4 cluster, ditentukan berdasarkan nilai Bayesian Information Criterion (BIC) terendah sebesar 1596,999 dari evaluasi rentang 1 hingga 10 cluster. Kedua, model GMM dengan 4 cluster menghasilkan empat kelompok pelanggan dengan karakteristik yang berbeda, yaitu Cluster 0 berupa pelanggan berusia lebih tua dengan pendapatan dan pengeluaran menengah (76 pelanggan), Cluster 1 berupa pelanggan berpendapatan dan pengeluaran tinggi (39 pelanggan), Cluster 2 berupa pelanggan muda dengan pengeluaran cukup tinggi (51 pelanggan), dan Cluster 3 berupa pelanggan berpendapatan tinggi namun pengeluaran rendah (34 pelanggan). Ketiga, kualitas hasil clustering yang dihasilkan oleh model GMM diukur menggunakan Silhouette Score dengan nilai sebesar 0,3734, yang menurut skala Kaufman dan Rousseeuw (1990) berada pada kategori struktur lemah hingga cukup, menunjukkan bahwa keempat cluster yang terbentuk dapat dibedakan meskipun masih terdapat tumpang tindih pada sebagian data antar cluster. Dengan demikian, seluruh rumusan masalah penelitian telah terjawab dan tujuan penelitian telah tercapai. Meskipun demikian, kualitas pemisahan cluster yang di peroleh masih menunjukkan adanya tumpang tindih pada Sebagian data sehingga hasil segmentasi ini masih memiliki peluang untuk di tingkatkan pada penelitian selanjutnya melalui penambahan fitur maupun penggunaan pendekatan clustering lainnya.

5.2. Saran

Berdasarkan hasil dan keterbatasan penelitian ini, terdapat beberapa saran yang dapat diberikan untuk penelitian selanjutnya. Pertama, penelitian selanjutnya dapat menambahkan fitur lain seperti jenis kelamin (Gender) atau data transaksi yang lebih detail untuk memperkaya hasil segmentasi pelanggan. Kedua, penelitian selanjutnya dapat membandingkan performa Gaussian Mixture Model (GMM) dengan metode clustering lain

seperti K-Means atau DBSCAN untuk melihat metode mana yang paling optimal pada dataset serupa. Ketiga, hasil segmentasi pelanggan pada penelitian ini dapat ditindaklanjuti dengan penyusunan strategi pemasaran yang lebih spesifik untuk setiap cluster, serta diuji dampaknya terhadap peningkatan penjualan atau loyalitas pelanggan pada penelitian selanjutnya. Penelitian selanjutnya juga dapat mengeksplorasi penggunaan metode reduksi dimensi seperti PCA sebelum proses clustering untuk mengetahui pengaruhnya terhadap kualitas segmentasi pelanggan.

DAFTAR PUSTAKA

- Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. New York: Springer.
- Han, J., Kamber, M., & Pei, J. (2012). *Data Mining: Concepts and Techniques* (3rd ed.). Waltham: Morgan Kaufmann.
- John, J. M., Shobayo, O., & Ogunleye, B. (2023). An Exploration of Clustering Algorithms for Customer Segmentation in the UK Retail Market. *Analytics*, 2(4), 809-823. <https://doi.org/10.3390/analytics2040042>
- Kaufman, L., & Rousseeuw, P. J. (1990). *Finding Groups in Data: An Introduction to Cluster Analysis*. New York: John Wiley & Sons.
- Kotler, P., & Keller, K. L. (2016). *Marketing Management* (15th ed.). Boston: Pearson.
- Laksana, E. A., & Fahrezi, M. M. (2024). Customer Segmentation and Analysis Based on Gaussian Mixture Model Algorithm. *Proceedings of the Widyatama International Conference on Engineering 2024 (WICOENG 2024)*, 67-75. https://doi.org/10.2991/978-94-6463-618-5_8
- Perdana, S. A., Florentin, S. F., & Santoso, A. (2022). Analisis Segmentasi Pelanggan Menggunakan K-Means Clustering Studi Kasus Aplikasi Alfabeta. *Sebatik*, 26(2), 446-457. <https://doi.org/10.46984/sebatik.v26i2.1991>
- Reynolds, D. A. (2009). Gaussian Mixture Models. Dalam S. Z. Li & A. Jain (Eds.), *Encyclopedia of Biometrics* (hlm. 659-663). Boston: Springer.
- Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20, 53-65.
- Tan, P. N., Steinbach, M., & Kumar, V. (2019). *Introduction to Data Mining* (2nd ed.). New York: Pearson.
- Tsitsis, K., & Chorianopoulos, A. (2011). *Data Mining Techniques in CRM: Inside Customer Segmentation*. West Sussex: John Wiley & Sons.

LAMPIRAN-LAMPIRAN

1. Surat pengantar/permohonan data (Jika dibutuhkan)
2. Form Bimbingan
3. Source code dan data: berkas source code program (project_GMM.ipynb) dan dataset (Mall_Customers.csv) yang digunakan dalam penelitian ini dilampirkan secara terpisah bersama laporan skripsi.
4. Struktur data: dataset Mall Customers terdiri atas 200 baris data dengan kolom CustomerID, Gender, Age, Annual Income (k\$), dan Spending Score (1-100). Contoh 50 data pada baris awal dan 50 data pada baris akhir disajikan pada lampiran berikutnya.
5. Visualisasi hasil eksplorasi data (EDA), grafik BIC dan AIC, serta visualisasi hasil clustering dilampirkan pada bagian akhir lampiran.
6. Dokumentasi penelitian (Jika melakukan observasi)